Caracterización transcriptómica de la respuesta a DPN y OHT mediante RNA-seq en cultivos primarios de tumores paratiroideos

Máster en Bioinformática y Ciencia de Datos en Medicina Personalizada de Precisión y Salud

Autor

Álvaro García Barragán

Marzo, 2026

Índice

1. Introducción **1**

2. Diseño Experimental **1**
2.1. Detalles Biológicos de las Muestras 1
2.2. Datos de Entrada 1

3. Protocolo bioinformático **2**

4. Control de Calidad **2**
4.1. Calidad de Lecturas 2
4.2. Calidad de Alineamiento 4
4.3. Calidad de Conteo 4

5. Análisis de Expresión Diferencial **5**
5.1. Exploración de Muestras de Expresión 5
5.2. Test de Hipótesis 5

6. Análisis de Enriquecimiento de Genes **7**

7. Detalles técnicos y reproducibilidad **8**

Referencias **9**

1. Introducción

En este documento se describe el desarrollo de un análisis bioinformático de RNA-seq para estudiar la expresión génica en células de tumores paratiroideos, con el objetivo final de evaluar la eficacia de dos fármacos.

El documento se organiza en seis secciones principales. En primer lugar, en la Sección 2 se presenta el diseño experimental junto con los datos. A continuación, la Sección 3 describe el protocolo bioinformático empleado, incluyendo las herramientas utilizadas. La sección Sección 4 analiza las métricas de secuenciación y alineamiento. Posteriormente, en la Sección 5 se presenta el análisis de expresión diferencial y, en la Sección 6, el análisis de enriquecimiento génico. Finalmente, en la Sección 7 se describe el software utilizado para garantizar la reproducibilidad del experimento.

2. Diseño Experimental

2.1. Detalles Biológicos de las Muestras

El experimento se realizó utilizando 24 cultivos primarios de tumores paratiroideos[1], todos negativos para receptores de estrógenos alfa (ERα), procedentes de 4 pacientes diferentes. Cada cultivo fue tratado con dos fármacos distintos: diarilpropionitrilo (DPN) , un agonista del ERα, o 4hidroxitamoxifeno (OHT), un inhibidor competitivo de los receptores de estrógenos, a dos tiempos distintos: 24 h y 48 h.

2.2. Datos de Entrada

Todos los datos utilizados se pueden ver en Tabla 1. Para el primer apartado, se trabajó con un subset de 2 muestras (SRR479052 y SRR479054), a partir de un total de 4 archivos fastq paired-end, correspondientes a las lecturas forward y reverse de cada muestra

Para el segundo apartado, se utilizaron los 24 cultivos completos, incluyendo metadatos asociados al experimento (id del paciente, farmaco, tiempo de toma de la muestra) y matrices de cuentas crudas para realizar análisis de expresión diferencial y GSEA.

Además, se descargó de internet el archivo de anotación `Human_Ensembl_Gene_ID_MSigDB`[2] para el análisis de GSEA, que permite mapear identificadores de genes de Ensembl a los conjuntos de genes definidos en MSigDB

Ficheros	**Descripción**
Apartado 1	
`SRR479052.chr21_1.fastq, SRR479052.chr21_2.fastq`	Lecturas paired-end de SRR479052
`SRR479054.chr21_1.fastq, SRR479054.chr21_2.fastq`	Lecturas paired-end de SRR479054
`Homo_sapiens.GRCh38.dna.chromosome.21.fa`	Secuencia de referencia del cromosoma 21
`Homo_sapiens.GRCh38.109.chr21.gtf`	Anotación génica del cromosoma 21
Apartado 2	
`rawcounts.tsv`	Matriz de cuentas de los 24 cultivos
`metadata.tsv`	Metadatos del experimento
`DPN_response.gmt`	Archivo GMT para GSEA de genes DPN
`Human_Ensembl_Gene_ID_MSigDB.v2023.2.Hs.chip`	Archivo de anotación para GSEA

Cuadro 1: Ficheros usados para el análisis de RNA-seq en cada apartado.

[1] https://www.cancer.gov/espanol/tipos/paratiroides/paciente/tratamiento-paratiroides-pdq
[2] https://data.broadinstitute.org/gsea-msigdb/msigdb/annotations/human/

3. Protocolo bioinformático

El análisis bioinformático se llevó a cabo mediante un *pipline* estructurado en varios pasos. Inicialmente, las lecturas en formato `.fastq` fueron procesadas mediante *trimming* utilizando el módulo *Cutadapt* [1]. Posteriormente, las lecturas filtradas se alinearon con *Hisat2* [2], generando archivos `.sam`. A continuación, estos archivos fueron cuantificados con *HTSeq* [3], obteniéndose ficheros de cuentas `.htseq`. Todos estos pasos fueron automatizados y se realizó un análisis de control de calidad mediante *MultiQC* [4].

Posteriormente, a partir de la matriz de cuentas, se llevó a cabo un análisis de expresión diferencial (*Differential Gene Expression*, DGE) con la herramienta DESeq2 [5], así como un análisis de enriquecimiento de genes (*Gene Set Enrichment Analysis*, GSEA) [6].

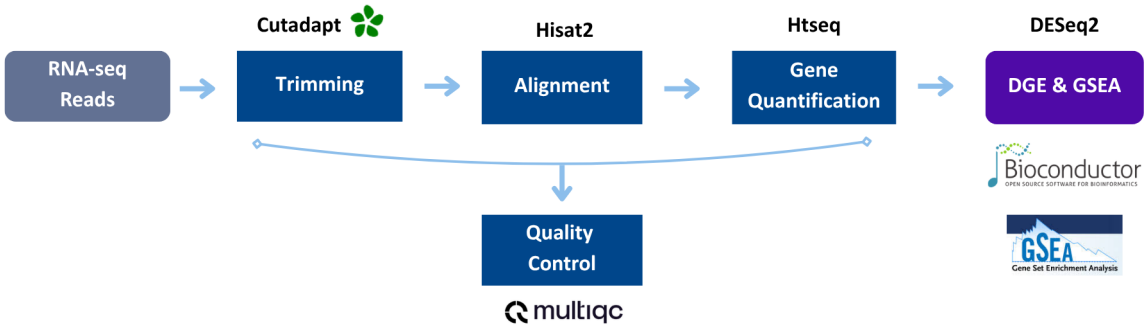

Figura 1: RNASeq *pipline* Bioinformático.

4. Control de Calidad

La calidad del proceso de obtención de la matriz de conteo de genes se evalúa a distintos niveles. En primer lugar, se analiza la calidad de las lecturas crudas generadas tras el alineamiento y después de su recorte y filtrado (véase Subsección 4.1). A continuación, se evalúa la calidad del alineamiento de las lecturas procesadas (véase Subsección 4.2). Finalmente, se examina la calidad del conteo de genes (véase Subsección 4.3).

4.1. Calidad de Lecturas

La Tabla 2 muestra las estadísticas del proceso de recorte y filtrado de las lecturas para ambas muestras.

Metric	**SRR479052.chr21**	**SRR479054.chr21**
	Pair Level	
Total read pairs processed	15,340	9,746
Read 1 with adapter	3,576 (23.3 %)	1,892 (19.4 %)
Read 2 with adapter	3,932 (25.6 %)	2,109 (21.6 %)
Pairs too short	1,552 (10.1 %)	1,022 (10.5 %)
Pairs passing filters	13,788 (89.9 %)	8,724 (89.5 %)
	Base Level	
Total basepairs processed	3,098,680 bp	1,968,692 bp
Quality-trimmed bases	579,736 bp (18.7 %)	368,704 bp (18.7 %)
Total bases written (filtered)	2,351,298 bp (75.9 %)	1,499,980 bp (76.2 %)

Cuadro 2: Estadísticas de Lecturas.

En general, se observa que la proporción de lecturas con adaptadores es moderada, situándose entre el 19 % y el 26 %. Aproximadamente un 10 % de los pares de lecturas fueron descartados por longitud insuficiente tras el recorte, mientras que cerca del 90 % superaron los filtros de calidad en ambas muestras, indicando una buena retención de datos. Asimismo, el porcentaje de bases recortadas por calidad es muy similar en ambos casos (18.7 %), lo que sugiere una calidad comparable entre las muestras.

Por otra parte, en la Figura 2 se muestran las ocho muestras analizadas: las cuatro en rojo corresponden a lecturas sin filtrar y las cuatro en verde a las mismas muestras tras el filtrado. Después del proceso, el *phred score* promedio en todas las posiciones supera 30, evidenciando una mejora notable en la calidad. Para lograrlo, Cutadapt eliminó lecturas de longitud inferior a 20 nucleótidos, evitando fragmentos demasiado cortos que podrían mapearse de manera inespecífica, y descartó lecturas con *phred score* menor a 28, asegurando que solo se retuvieran secuencias con baja probabilidad de error.

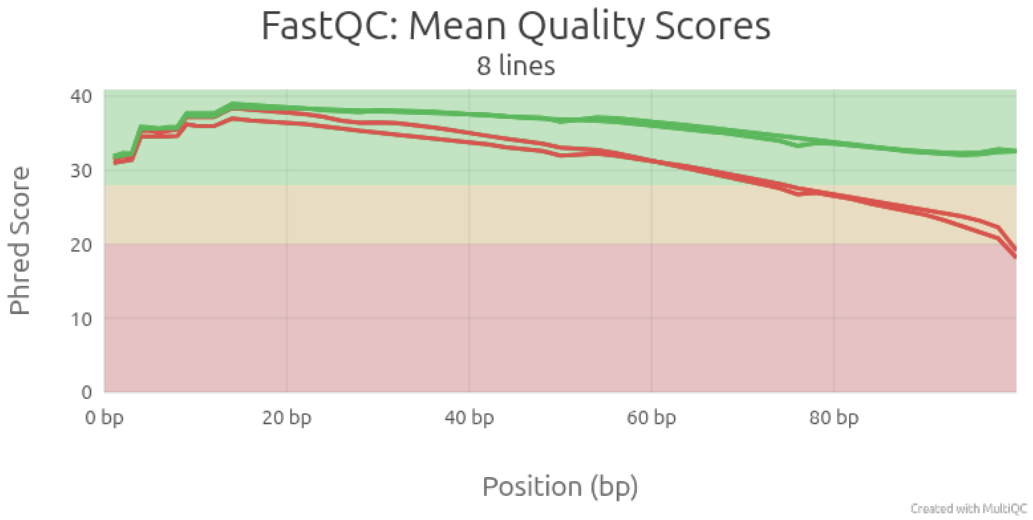

Figura 2: Media de *phred score* por base de FastQC.

Finalmente, la Tabla 3 muestra las métricas resumen de MultiQC antes y después del *trimming*. Los porcentajes de lecturas duplicadas son bajos ($\sim 6\,\%$) y el contenido de GC se mantiene estable (49–52 %), indicando buena diversidad y ausencia de sesgos. Las longitudes media y mediana de las lecturas se reducen en aproximadamente 15 pb, como es de esperar, ya que el *trimming* eliminó adaptadores y regiones finales de baja calidad.

Sample	**Dups**	**GC**	**Avg Len**	**Median Len**
Untrimmed Reads				
SRR479052.chr21_1	6.4 %	52 %	101 bp	101 bp
SRR479052.chr21_2	6.2 %	52 %	101 bp	101 bp
SRR479054.chr21_1	5.8 %	51 %	101 bp	101 bp
SRR479054.chr21_2	5.6 %	51 %	101 bp	101 bp
Trimmed Reads				
SRR479052.chr21_1	6.2 %	50 %	84 bp	92 bp
SRR479052.chr21_2	6.3 %	50 %	86 bp	94 bp
SRR479054.chr21_1	5.8 %	49 %	85 bp	94 bp
SRR479054.chr21_2	5.9 %	49 %	87 bp	96 bp

Cuadro 3: Resumen de MultiQC para muestras de RNASeq antes y después del *trimming*.

4.2. Calidad de Alineamiento

La calidad de alineamiento de las muestras es excelente, con un éxito de mapeo total superior al 90 %, lo que indica que la secuenciación y la preparación de las librerías fueron adecuadas. La mayoría de los fragmentos, alrededor del 80 %, se alinean de manera única y correcta, mientras que entre el 10 y el 12 % presentan alineamiento parcial, correspondiendo a casos en los que solo un mate (una lectura del par) se alinea o los pares son discordantes. Aproximadamente un 8 % de las lecturas no se alinean, probablemente debido a ruido o secuencias ausentes en la referencia. Ambas muestras muestran perfiles casi idénticos, evidenciando consistencia y ausencia de sesgos técnicos relevantes.

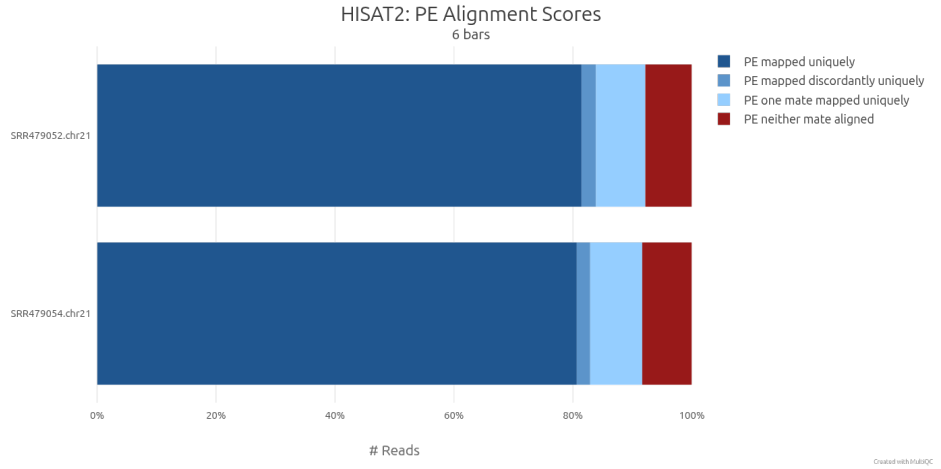

Figura 3: Calificación de Alineamiento de Lecturas Pareadas con HIST2.

4.3. Calidad de Conteo

La Figura 4 muestra la asignación de lecturas a genes específicos. Aproximadamente el 48 % de las lecturas fueron asignadas correctamente a un gen, mientras que un 15-18 % se alineó a regiones sin genes. Un bloque considerable, alrededor del 32 %, presenta baja calidad de alineamiento y no se utiliza, y un 2 % cae en regiones ambiguas donde se solapan varios genes.

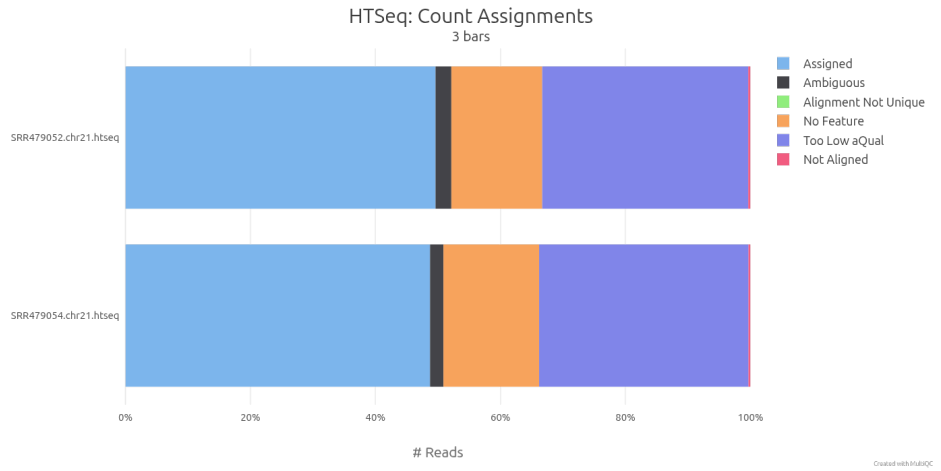

Figura 4: Asignación de Conteos con HTSeq.

5. Análisis de Expresión Diferencial

El análisis diferencial está dividido en dos pasos. En primer lugar, se visualizaron los datos para comprobar si existían valores atípicos o *batch effects* (Subsección 5.1). Posteriormente, con los datos seleccionados, se procedió al análisis de expresión diferencial, donde se realizan los tests de hipótesis estadísticos (Subsección 5.2).

5.1. Exploración de Muestras de Expresión

La matriz de expresión consta de 24 muestras y 53.160 genes; tras eliminar aquellos genes con menos de 10 conteos, se obtienen 24.416 genes.

En primer lugar se realizó una descomposición en componentes principales para cada variable de metadata: paciente, tiempo y fármaco. No se detectó ningún *batch effect*, excepto en paciente, donde, como se muestra en Figura 5, las muestras quedan agrupadas por paciente, lo que indica que la expresión entre pacientes varía poco, salvo en el caso de la muestra control del paciente 4 (GSM913896), que queda agrupada con las muestras del paciente 3.

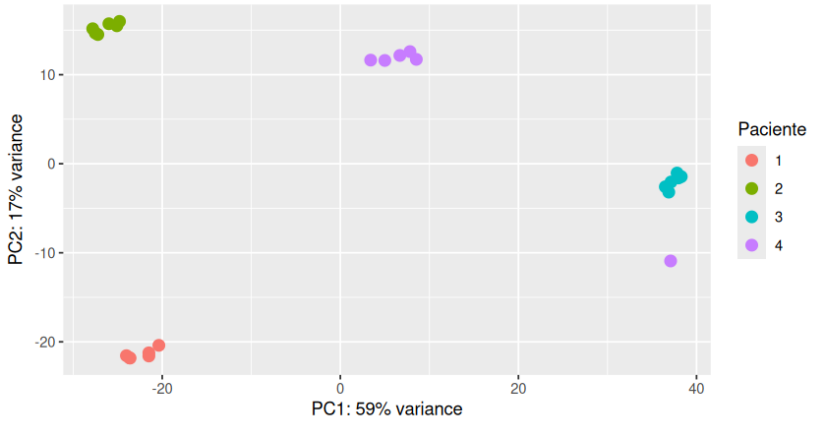

Figura 5: Componentes principales (PCA) de muestras agrupadas por paciente.

Por ello, esta muestra se eliminó y se incluirá la variable paciente en el análisis diferencial para modelar el *batch effect*.

5.2. Test de Hipótesis

El experimento se diseñó para responder a las siguientes preguntas:

- **RQ1**: ¿Qué genes se encuentran diferencialmente expresados entre las muestras tratadas con OHT respecto al control tras 24 h?
- **RQ2**: ¿Y qué ocurre en el caso de las muestras tratadas con DPN, también tras 24 h?

Por ello, para el test de hipótesis solo se seleccionaron las muestras correspondientes a las 24 h, quedando un total de 11 muestras (12-1).

El test de hipótesis elegido fue el **Wald**, para determinar si la expresión de un gen difiere entre condiciones (DPN vs control y OHT vs control). Inicialmente se usó `lfcThreshold = 1`, pero no se encontró ningún gen significativo (es decir, genes con cambio ≥ 2 veces en conteos). Por ello, se utilizó `lfcThreshold = 0`, donde la hipótesis nula (H_0) es que el cambio es 0, para ser menos restrictivos y detectar posibles diferencias de expresión.

Los genes significativamente diferencialmente expresados se muestran en azul en Figura 6.

Para **RQ1** se identificaron 4 genes diferencialmente expresados, siendo RERE-AS1 el único con un *log2 fold change* mayor que 1, lo que indica un efecto biológicamente relevante. Esto sugiere que OHT provoca cambios específicos en un conjunto limitado de genes tras 24 h, con magnitudes bajas en la mayoría de ellos.

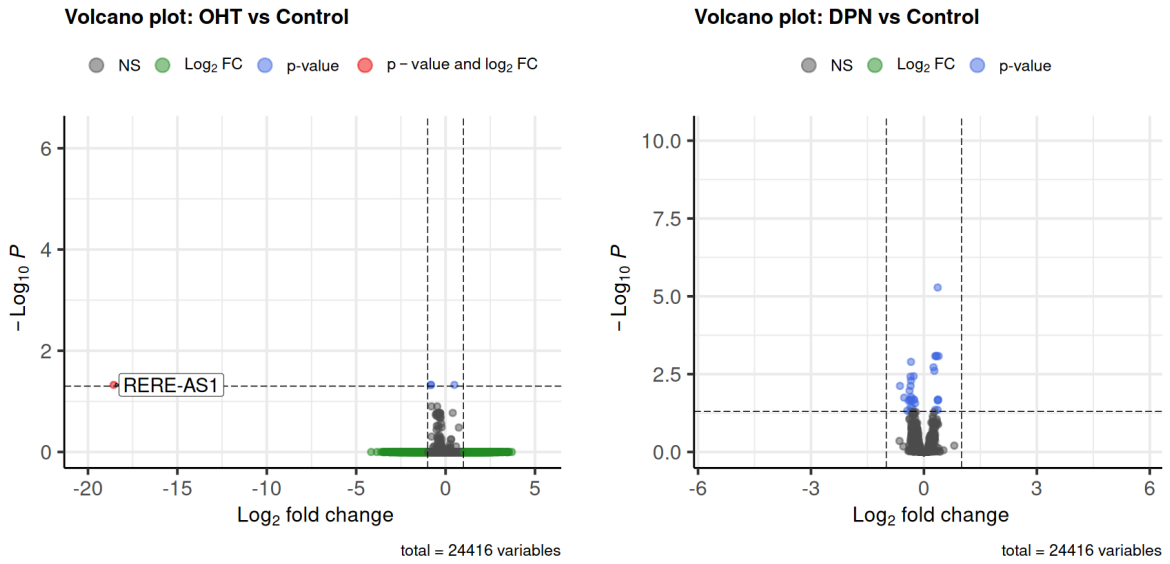

Figura 6: Genes diferencialmente expresados a las 24h.

Para **RQ2** se detectaron 32 genes, pero ninguno con cambios relevantes, lo que indica que DPN tiene un impacto mínimo sobre la expresión génica.

La distribución de las cuentas normalizadas de RERE-AS1 se muestra en Figura 7, donde se observa que la diferencia promedio entre control y OHT es mínima.

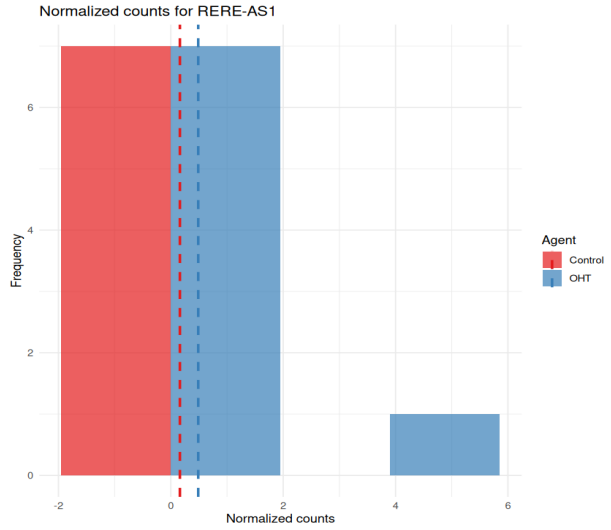

Figura 7: Distribución de cuentas normalizas para el gen RERE-AS1.

En conjunto, estos resultados indican que los efectos transcripcionales son limitados, y que OHT induce una respuesta más amplia que DPN.

6. Análisis de Enriquecimiento de Genes

El análisis GSEA se realizó utilizando la herramienta grafica GSEA [6] con el método pre-ranked a partir de la expresión diferencial previamente obtenida y de la respuesta al fármaco DPN proporcionada por nuestro colaborador. A los estadísticos generados en el test de hipótesis DPN vs control se les aplicó un *shrinkage* usando el método *apeglm* para obtener estimaciones más estables del cambio de expresión génica [7] tal y como se muestra en Figura 8.

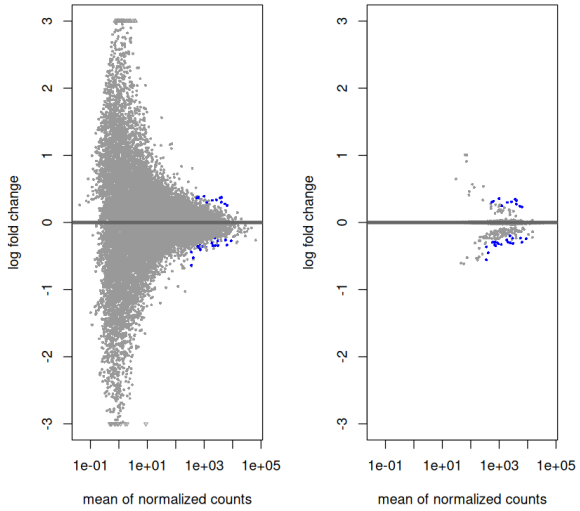

Figura 8: Distribución *log2 fold change* antes y después de *shrinkage* en el test DPN vs Control.

Los resultados tal y como se muestran en Figura 9 se observa un enriquecimiento claro de los conjuntos de genes. DPN_PERTURBED presenta un enriquecimiento positivo, con la mayoría de sus genes concentrados en la parte superior de la lista ordenada ($ES = 0{,}80$), mientras que DPN_UNPERTURBED presenta un enriquecimiento negativo, con la mayoría de sus genes concentrados en la parte inferior de la lista ($ES = -0{,}76$).

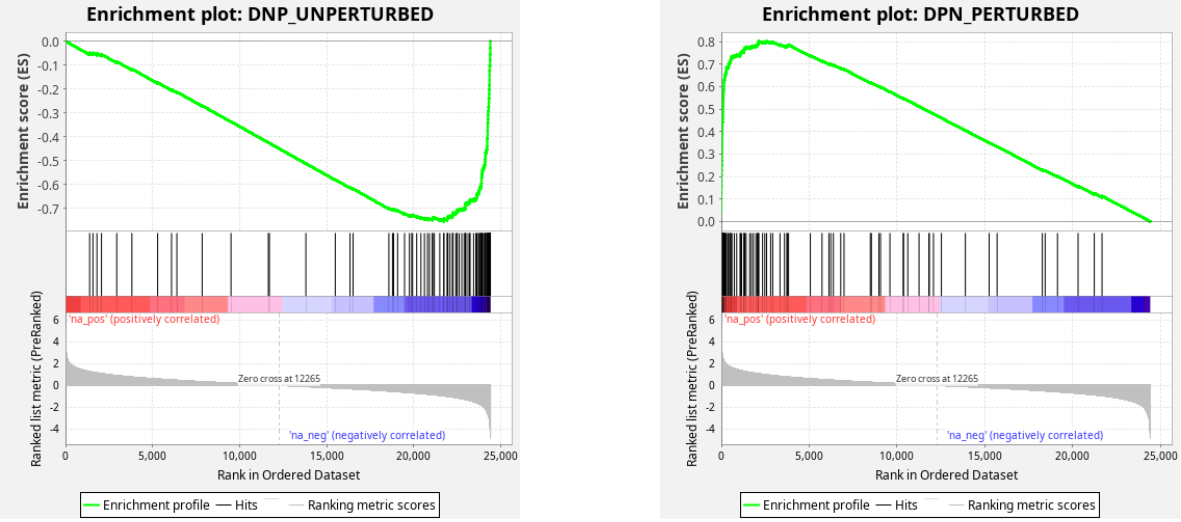

Figura 9: Enriquecimiento funcional en conjuntos de genes tratado y sin tratar.

En conclusión, estos resultados indican que DPN induce cambios significativos en los conjuntos de genes a las 24 horas, por lo que el fármaco tiene efecto.

7. Detalles técnicos y reproducibilidad

La ejecución de todos los programas del experimento se realizo en un sistema *VANT MOOVE15* con las siguientes especificaciones:

- **CPU:** Intel(R) Core(TM) 5 120U, 10 núcleos físicos, 12 hilos, caché L3 de 12 MB, soporta SSE, SSE2, SSE4.1, SSE4.2, AVX y AVX2.
- **Memoria:** 32 GB de RAM total, aproximadamente 25 GB disponibles para el sistema, sin uso de swap durante las pruebas.
- **Sistema operativo:** Ubuntu 24.04, kernel 6.14.0-35-generic, arquitectura x86_64.
- **Herramientas utilizadas:**
  - HISAT2 2.2.2
  - HTSeq 2.0.9
  - MultiQC 1.33
  - FastQC 0.12.1
  - Cutadapt 5.2
  - Rseqc 5.0.4
  - Samtools 1.17
  - FeatureCounts 2.0.1
  - DESeq2 1.40.2

Para cada apartado existe un entorno de conda diferente:

- Apartado 1: `DGE.yml`
- Apartado 2: `RNASeq.yml`

Todo código está disponible en el https://github.com/Alvaro8gb/transcriptomic-final-exercise.

Para ejecutar el Apartado 1 es necesario estos comandos:

Apartado 1 CLI

```
conda env create -f envs/RNASeq.yml
chmod +x scripts/main.sh
./scripts/main.sh
```

Para ejecutar el Apartado 2 es necesario estos comandos:

Apartado 2 CLI

```
conda env create -f envs/DGE.yml
Rscript -e "IRkernel::installspec()"
# Run All dge.ipynb
# Run All gsea.ipynb
# Run GSEA tool
```

La herramienta GSEA se ejecutó con 1,000 permutaciones y la opción *no collapse* activada, lo que permite evaluar la significancia de los conjuntos de genes sin agrupar los probes a nivel de genes, manteniendo la resolución original de los datos.

Referencias

[1] Marcel Martin. «CUTADAPT removes adapter sequences from high-throughput sequencing reads». En: *EMBnet.journal* 17 (ago. de 2011). DOI: 10.14806/ej.17.1.200.

[2] Daehwan Kim et al. «Graph-based genome alignment and genotyping with HISAT2 and HISAT-genotype». En: *Nature Biotechnology* 37.8 (2019), págs. 907-915. ISSN: 1546-1696. DOI: 10.1038/s41587-019-0201-4.

[3] Givanna H Putri et al. «Analysing high-throughput sequencing data in Python with HTSeq 2.0». En: *Bioinformatics* 38.10 (mar. de 2022), págs. 2943-2945. ISSN: 1367-4803. DOI: 10.1093/bioinformatics/btac166.

[4] Philip Ewels et al. «MultiQC: summarize analysis results for multiple tools and samples in a single report». En: *Bioinformatics* 32.19 (2016), pág. 3047. DOI: 10.1093/bioinformatics/btw354.

[5] Michael I. Love, Wolfgang Huber y Simon Anders. «Moderated estimation of fold change and dispersion for RNA-seq data with DESeq2». En: *Genome Biology* 15.12 (2014), pág. 550. ISSN: 1474-760X. DOI: 10.1186/s13059-014-0550-8.

[6] Aravind Subramanian et al. «Gene set enrichment analysis: A knowledge-based approach for interpreting genome-wide expression profiles». En: *Proceedings of the National Academy of Sciences* 102.43 (2005), págs. 15545-15550. DOI: 10.1073/pnas.0506580102.

[7] Anqi Zhu, Joseph G Ibrahim y Michael I Love. «Heavy-tailed prior distributions for sequence count data: removing the noise and preserving large differences». En: *Bioinformatics* 35.12 (nov. de 2018), págs. 2084-2092. ISSN: 1367-4803. DOI: 10.1093/bioinformatics/bty895.